

投资组合多元化——从Markowitz到DeMiguel:

如何降低模型估计误差,少即是多?

Haozhe Xu

1 引言

投资组合多元化是现代金融学的核心原则，旨在通过分散投资降低风险并优化收益，也就是优化模型这回事儿。Markowitz（1952）提出的均值-方差优化框架为我们如何去选择投资组合提供了理论基础，通过估计资产的预期收益和协方差矩阵构建风险-收益最优的投资组合。然而，实际应用中，各类模型对这个矩阵的估计高度敏感，因此估计误差成为优化的主要障碍，尤其是预期收益和协方差的估计误差常常导致样本外表现不佳。为解决这一问题，经济学家们提出了多种改进方法，包括分离定理、资产定价模型、估计误差分析、协方差矩阵改进、简单策略以及动态调整方法等，以应对模型估计误差带来的挑战。本综述考察了解决这些问题的最新进展，以如何降低估计误差为线索串联文章，重点关注DeMiguel等人在《Management Science》和《The Review of Financial Studies》上发表的两项关键研究。这些研究探讨了创新的优化框架和朴素分散化的惊人效果，并将其置于顶级期刊更广泛文献的背景中，阐释为什么“少即是多”——即朴素分散化策略规避了模型参数的估计误差，使得更朴素的策略有可能产生更优的结果。最后简略阐述了DeMiguel之后，经济学家如何进一步提出更多的优化模型，以及这些模型与1/N朴素策略的比较。

2 早期优化模型的发展脉络&它们如何降低估计误差

投资组合理论在降低模型估计误差方面经历了从Markowitz的均值-方差模型到Tobin的分离定理、Sharpe的CAPM、Merton的连续时间模型，再到Ledit & Wolf的收缩估计和DeMiguel的1/N策略等一系列发展。这些理论都在寻找一个合理的优化模型以求最大程度地降低估计误差。

1. Markowitz的均值-方差模型:Markowitz在1952年提出了均值-方差模型，开创了现代投资组合理论。该模型通过最小化投资组合的方差（风险）来实现给定预期收益下的最优资产配置：他指出资产间的协方差是风险分散的关键，投资者应根据预期收益和风险的权衡选择投资组合。
2. Tobin的分离定理:James Tobin在1958年扩展了Markowitz的理论，提出了分离定理：他引入了无风险资产的概念，认为投资者的最优投资组合可以分解为两部分：无风险资产和风险资产的有效边界组合。

3. Sharpe的资本资产定价模型:William F. Sharpe在1964年提出了资本资产定价模型（CAPM），将市场均衡引入投资组合理论：CAPM假设所有投资者采用均值-方差优化，市场达到均衡时，资产的预期收益由其系统性风险（ β ）决定。
4. Merton的连续时间模型:Robert C. Merton在1971年将投资组合理论扩展到连续时间框架，提出了基于随机微积分的投资组合优化模型：他假设资产价格遵循几何布朗运动，投资者可以在连续时间内动态调整投资组合。
5. Jobson & Korkie的研究:J. D. Jobson和Bob Korkie在1980年研究了估计误差对投资组合表现的影响：他们开发了统计检验方法，量化估计误差对均值-方差优化的干扰，指出资产数量增加时误差效应更为显著。
6. Michaud的“估计误差问题”:Richard O. Michaud在1989年明确提出了“估计误差问题”，认为均值-方差优化在样本外的表现不佳源于参数估计的不准确：他建议使用bootstrap等模拟方法评估投资组合的稳定性，并提出了“resampled efficiency”方法。
7. Ledoit & Wolf的收缩估计:Olivier Ledoit和Michael Wolf在2003年和2004年提出了收缩估计方法，通过将样本协方差矩阵与结构化协方差矩阵进行加权平均，显著提高了估计的稳定性和准确性，这种方法特别适用于高维资产组合，降低了估计误差的影响。
8. Jagannathan & Ma的权重限制:Ravi Jagannathan和Tongshu Ma在2003年发现，通过对投资组合权重施加限制（如禁止卖空等），可以间接改进协方差矩阵的估计，即使所施加的限制并非最优，也能通过减少误差提升表现。
9. DeMiguel的1/N策略:Victor DeMiguel等人在2009年对比了最优多元化策略与1/N策略的表现：他们发现，在考虑估计误差后，1/N策略在样本外的表现往往优于复杂的均值-方差优化，凸显了简单策略的稳健性。

3 DeMiguel等人（2009）研究概览

因为在小组论文中已经详细解释论文详情，在此不做赘述，只简单总结两篇文章的主要内容与核心观点。

3.1 《Optimal Versus Naive Diversification: How Inefficient is the 1/N Portfolio Strategy?》

在这篇文章中，DeMiguel等人通过七个实证数据集和模拟数据，系统比较了14种投资组合优化模型与1/N策略的样本外表现。评价指标包括夏普比率、确定性等价收益（CEQ）和换手率，反映了收益、风险调整收益和交易成本的综合考量。他们采用滚动窗口的方式评估模型最终证实了1/N策略的优越性：在所有实证数据集上，14种优化模型均未能在夏普比率、CEQ收益或换手率方面持续优

于1/N策略，其中样本均值-方差投资组合因估计误差导致的极端权重使得这个策略表现尤为不佳（Best & Grauer, 1991）。

3.2 《A Generalized Approach to Portfolio Optimization Improving Performance by Constraining Portfolio Norms》

在这篇文章中，DeMiguel通过在传统最小方差问题中引入投资组合权重向量的范数约束，解决估计误差问题。他们使用五组月度资产回报数据集（包括10个和48个行业资产组合、6个和25个Fama-French资产组合，以及500只CRSP股票）评估了所提策略的样本外表现。比较对象包括1/N资产组合、传统最小方差资产组合、贝叶斯方法以及Ledoit和Wolf的收缩策略。所使用的评估指标涵盖夏普比率、确定性等价收益和周转率。研究的核心是在如何去对最小方差组合去进行约束的——通过添加约束条件，即权重向量的某种范数（如1-范数、2-范数或A-范数）小于某一阈值。他们的实证结果展示了DeMiguel等人如何嵌套Jagannathan和Ma（2003）以及Ledoit和Wolf（2003, 2004）的收缩方法，并证明了其在样本外表现（如夏普比率和确定等价收益）上的优越性：所提策略在大多数数据集上表现优于基准策略，尤其是在夏普比率和确定性等价收益方面

4 各模型缺点与和1/N策略的比较

Markowitz的均值-方差模型对预期收益和协方差矩阵的估计高度敏感，这一点会造成样本数据中的微小误差可能导致组合权重剧烈变化，样本外表现不佳，这种“误差最大化”特性源于模型对输入参数的过度依赖，尤其在高维资产组合中——样本协方差矩阵的不稳定性进一步放大了估计误差；Tobin的分离模型仍需依赖市场组合的估计，也就意味着误差问题并未完全解决；Sharpe的资本资产定价模型（CAPM）依赖市场组合的协方差和收益估计，所以仍然会受到样本数据噪声的影响；Merton的连续时间框架理论上提高了估计精度，但在实际中需要高频数据和高计算能力，复杂性增加了参数估计的不确定性，尤其在数据不足时，估计误差仍然显著；Jobson和Korkie的统计检验方法，量化了样本协方差矩阵误差对均值-方差优化的干扰，但他们发现，随着资产数量增加，估计误差显著放大，导致优化组合偏离理论最优；Michaud的“估计误差问题”，指出均值-方差优化在样本外的表现不佳源于对预期收益和协方差的不准确估计，虽然他提出“重抽样效率”方法虽然引入鲁棒性降低了估计误差，但计算复杂性较高，且对样本质量要求较高，限制了其实用性；Ledoit和Wolf的收缩估计方法特别适用于高维资产组合，能够有效降低协方差矩阵的估计误差，但运用范围有限；Jagannathan和Ma的方法与Ledoit和Wolf的收缩估计有异曲同工之妙，都通过引入约束或正则化降低估计误差，但Jagannathan和Ma的方法更简单，直接作用于权重而非协方差矩阵。

DeMiguel的1/N策略其核心优势在于完全避免了参数估计，消除了预期收益和协方差矩阵的估计误差。1/N策略的“无参数”特性使其对市场不确定性具有天然鲁棒性，等权重分配本质上是对权重施加了L1范数约束，与Jagannathan和Ma的权重约束思路一致，但更加简洁。DeMiguel的研究表明，复杂模型的“误差最大化”特性可能导致样本外表现不佳，而1/N策略通过极简的方式实现了“少即是多”。此

外，1/N策略的低换手率降低了交易成本，进一步增强了其实践价值。

综合对比，Markowitz的均值-方差模型通过数学优化追求理论最优，但对估计误差高度敏感；Tobin的分离定理通过引入无风险资产简化选择，间接降低误差；Sharpe的CAPM通过市场组合减少参数估计需求；Merton的连续时间模型通过动态调整提高精度，但复杂性增加误差风险；Jobson和Korkie量化了误差影响，提示需要稳健方法；Michaud的bootstrap方法通过统计平滑降低误差，但计算成本高；Ledoit和Wolf的收缩估计通过正则化提高协方差估计精度；Jagannathan和Ma的权重约束通过限制优化空间间接降低误差；而DeMiguel的1/N策略通过完全避免参数估计实现了最大程度的误差规避。从复杂到简约，这些模型在降低估计误差的路径上逐步演进，1/N策略以其极简性和鲁棒性成为“少即是多”的典范。

5 为什么能实现“少即是多”

在我看来，朴素分散化策略能够实现少即是多的效果，最主要的原因就是其对投资组合优化中“估计误差”和“模型复杂性”的天然规避。

5.1 规避参数估计误差：复杂模型的“阿喀琉斯之踵”

传统优化模型的致命缺陷在于输入敏感性：在Markowitz 均值 - 方差模型依赖对资产预期收益和协方差矩阵的精确估计，但微小的估计误差会导致优化权重的极端偏离（Michaud, 1989）。例如：预期收益的估计需长期历史数据（DeMiguel 等发现，25 个资产需约 3000 个月数据才能让优化模型超越 1/N），而现实中数据长度远不足（Merton, 1980）。而且协方差矩阵在高维场景下易出现“病态估计”，Ledoit & Wolf（2003）的收缩估计虽改进稳定性，但仍无法完全消除误差。

1/N 策略的“无参数优势”使得无需估计任何参数，直接等权重分配资金。这使得1/N策略能拥有极长时间维度和极广使用范围。理论推导表明，优化模型超越 1/N 所需的“临界数据窗口”远超实际可用数据，使得 1/N 在现实中成为更稳健的选择。

5.2 稳健性优势：简单策略对市场不确定性的适应性

5.2.1 权重约束的天然合理性

1/N 策略本质上是对投资组合权重施加了“L1 范数约束”（每个资产权重相等），这种约束自然避免了复杂模型因估计误差导致的极端权重（如单一资产占比过高）。文档提到，Jagannathan & Ma（2003）证明，即使施加“非最优约束”（如禁止卖空）也能通过减少误差提升表现，而 1/N 是一种极端但有效的约束形式。

5.2.2 对不同特性资产的普适性

当资产多元化程度高（如指数基金）时，1/N 因特质波动率低而损失更小；当资产相关性波动或市场环境变化时，复杂模型依赖的“静态协方差假设”失效，而 1/N 无需依赖历史相关性模式（De Nard

等，2016）。动态优化模型（如 Merton 连续时间模型）虽考虑时变性，但需估计更多参数，反而可能加剧误差（DeMiguel 等，2009）。

5.3 成本优势：交易成本与操作可行性

1/N 策略无需频繁调仓，换手率显著低于复杂模型，极大节约成本节约。文章中的实证结果显示，1/N 的交易成本（以换手率为代理）远低于均值 - 方差优化组合，而复杂模型为追求“最优权重”可能产生高换手率，从而抵消收益（Best & Grauer, 1991）。而其操作也具有简易性与可复制性：复杂模型（如贝叶斯收缩、机器学习）依赖高级统计技术和大量计算资源，而 1/N 策略无需专业知识即可实施。DeMiguel 等（2009）将其称为“稳健基准”，即使在另类资产（如债券、商品）中，1/N 也因低门槛和抗误差性保持竞争力（De Nard 等，2016）。

6 DeMiguel的1/N策略相比于同期的策略以及后续新发展的策略仍具优越性

在DeMiguel的研究基础上，学界发展出了更多优化模型，但对比与DeMiguel等人同期研究以及后续运用机器学习等更复杂的模型优化方法可以发现，1/N策略仍然具有优越性，可以看出，简化模型有时候可以得到更优的结果，这同样也反应了“少即是多”的哲学思想。

6.1 与DeMiguel等人的同期研究对比

与DeMiguel等人同期，Kan和Zhou（2007）提出“三基金”投资组合，通过结合风险资产、无风险资产和最小方差投资组合降低估计风险。DeMiguel等人测试了该模型，但发现其样本外表现仍不及1/N。Brandt等人（2009）提出了一种基于资产横截面特征（如规模、账面市值比）的投资组合构建方法，试图绕过传统时刻估计。DeMiguel等人对其进行了评估，认为该方法在资产数量较大时有潜力，但高换手率限制了其实践效果。

6.2 同后续研究发展的对比

6.2.1 与风险平价策略的对比

风险平价（Risk Parity）策略通过均衡分配各类资产的风险贡献来构建组合，强调风险分散，而非收益最大化。Asness 等人（2012）将其与动量效应结合，提出动态调整以提升绩效，实证显示其在危机时期表现稳健。Fung 和 Hsieh（2014）进一步扩展其应用至另类资产。

然而，风险平价策略依赖于对资产波动率和相关性的估计，而这些参数在市场剧变时易产生误差，导致组合表现不佳。而1/N策略不需计算波动率或相关性，避免了估计误差，尤其在资产数量多时，其样本外表现更稳健，不受市场波动影响。

6.2.2 与机器学习与组合优化的融合&深度强化学习与多模态数据整合的对比

2009年后的研究在缓解估计误差和改进优化模型方面取得了显著进展。Kirby和Ostdiek（2012）提出范数约束投资组合，通过限制权重偏差提升样本外表现，在某些场景下优于1/N；Tu和Zhou（2011）开发了一种组合多种投资组合规则的框架，通过“混合”策略增强鲁棒性；机器学习技术逐渐应用于投资组合优化，Ban等人（2018）利用神经网络直接估计权重，绕过传统均值-协方差估计的局限；Gu等人（2020）通过随机森林和梯度提升树捕捉非线性关系，提升收益预测。深度强化学习（DRL）如Isaac等人（2024）整合多模态数据（股价、新闻情感等），显著提升绩效。

然而，这些方法需要大量数据和计算资源，且复杂模型易过拟合，泛化能力受限。而1/N策略简单易行，无需大量数据或复杂计算，实施成本低；可以避免过拟合，不依赖模型复杂度，在数据有限或市场变化时更稳健。

6.2.3 与过滤协方差矩阵改善动态模型的对比

动态资产配置模型考虑参数时变性，如Ang和Chen（2013）通过因子模型捕捉收益动态特征，Platanakis等人（2019）通过过滤协方差矩阵改善表现，Ledoit和Wolf（2017）提出非线性收缩估计器降低误差。

然而，DeMiguel等人指出，这些模型需估计更多参数，误差可能放大，未必优于1/N策略。1/N策略有很大低估估计误差：无需估计时变参数，避免复杂计算带来的风险。同时有强鲁棒性：在参数估计困难的情况下表现更稳定。

6.2.4 与流动性调整的动态优化的对比

Gârleanu和Pedersen（2013）将流动性风险纳入动态模型，提出“流动性螺旋”理论，通过交易成本和市场影响函数优化再平衡策略，在危机时期效果显著。后续研究基于PCA实现流动性与收益平衡。

然而，这些模型需估计流动性参数，存在不确定性。1/N策略的优势则无需流动性估计，不考虑复杂流动性参数，避免误差；因此适用性很广，在流动性波动大的市场中仍能保持稳定。

6.2.5 与时间序列动量策略的对比

Moskowitz等人（2012）在《Time Series Momentum》中发现，资产价格的时间序列动量效应普遍存在于股票、债券、商品等多个市场。该策略通过跟踪资产自身的历史收益趋势（绝对动量）进行多空操作，与传统横截面动量形成互补。实证显示，时间序列动量策略在58种资产中的平均夏普比率达0.176，尤其在趋势性强的市场中表现突出。但该策略依赖动量信号估计，易受趋势误判影响。而1/N策略的优势：无需趋势估计，避免因动量信号误差导致的风险；简单高效，在趋势不明朗的市场中表现更可靠。

6.2.6 将1/N策略扩展至多资产投资组合

此外，De Nard等人（2016）将分析扩展至多资产投资组合（如股票、债券、商品），发现1/N策略在某些条件下仍具竞争力。这些进展表明，1/N策略仍然简单有效，学术界仍在积极探索超越其表现的优化方法。

7 结论

投资组合优化在降低模型估计误差的方面，经历了从Markowitz的均值-方差模型到Tobin的分离定理、Sharpe的CAPM、Merton的连续时间模型，再到Ledoit & Wolf的收缩估计和DeMiguel的1/N策略等一系列发展，直至今日，随着大数据和机器学习技术的发展，投资组合优化进一步提升对估计误差的控制能力。但是1/N策略依然具有很高的运用价值以及全面的运用范围，极低的运用成本，这一点确立了1/N策略作为稳健基准的地位，为我们进行投资实践提供了“少即是多”的决策启示，有时候更简单的策略反而具有更好的优化效果，也是本次文献综述写作的核心内容。

8 reference

- Markowitz, H. M. (1952). Portfolio selection. *Journal of Finance*, 7(1), 77–91.
- Tobin, J. (1958). Liquidity Preference as Behavior Towards Risk. *Review of Economic Studies*, 25(2), 65-86.
- Sharpe, W. F. (1964). Capital Asset Prices: A Theory of Market Equilibrium under Conditions of Risk. *Journal of Finance*, 19(3), 425-442.
- Merton, R. C. (1971). Optimum Consumption and Portfolio Rules in a Continuous-Time Model. *Journal of Economic Theory*, 3(4), 373-413.
- Jobson, J. D., & Korkie, B. (1980). Estimation for Markowitz Efficient Portfolios. *Journal of the American Statistical Association*, 75(371), 544-554.
- Michaud, R. O. (1989). The Markowitz Optimization Enigma: Is 'Optimized' Optimal? *Financial Analysts Journal*, 45(1), 31-42.
- Ledoit, O., & Wolf, M. (2003). Honey, I Shrunk the Sample Covariance Matrix. *Journal of Portfolio Management*, 30(4), 110-119.
- Ledoit, O., & Wolf, M. (2004). A Well-Conditioned Estimator for Large-Dimensional Covariance Matrices. *Journal of Multivariate Analysis*, 88(2), 365-411.
- Jagannathan, R., & Ma, T. (2003). Risk Reduction in Large Portfolios: Why Imposing the Wrong Constraints Helps. *Journal of Finance*, 58(4), 1651-1683.
- Ledoit, O., & Wolf, M. (2003). Improved estimation of the covariance matrix of stock returns with an application to portfolio selection. *Journal of Empirical Finance*, 10(5), 603-621.

- De Nard, G., Ledoit, O., & Wolf, M. (2016). Factor models for portfolio selection. *Journal of Financial Econometrics*, 16(4), 543–573.
- Kan, R., & Zhou, G. (2007). Optimal portfolio choice with parameter uncertainty. *Journal of Financial and Quantitative Analysis*, 42(3), 621–656.
- Kirby, C., & Ostdiek, B. (2012). It's all in the timing: Simple active portfolio strategies that outperform naive diversification. *Journal of Financial and Quantitative Analysis*, 47(2), 437-467.
- Ledoit, O., & Wolf, M. (2017). Nonlinear shrinkage of the covariance matrix. *Journal of Financial Econometrics*, 15(4), 633–670.
- Merton, R. C. (1980). On Estimating the Expected Return on the Market: An Exploratory Investigation. *Journal of Financial Economics* 8:323–61.
- E. Platanakis, D. Shtaxhuni, A. Urquhart . (2019). Robust portfolio optimization with filtered covariance matrices. *Finance Research Letters* 30:305–311.
- A. Ang, J. Chen. (2013). Factor models of asset returns. *Encyclopedia of Quantitative Finance*
- Tu, J., & Zhou, G. (2011). Markowitz meets Talmud: A combination of sophisticated and naive diversification strategies. *Journal of Financial Economics*, 99(1), 204-215.
- Ban, G. Y., El Karoui, N., & Lim, A. E. B. (2018). Machine learning and portfolio optimization. *Management Science*, 64(3), 1136-1154. <https://doi.org/10.1287/mnsc.2016.2644>
- Asness, C. S., Frazzini, A., & Pedersen, L. H. (2012). Risk Parity and Momentum. *Journal of Portfolio Management*, 38(5), 12-28.
- Gu, S., Kelly, B., & Xiu, D. (2020). Machine Learning in Asset Management. *Review of Financial Studies*, 33(5), 1903-1947.
- Gârleanu, N., & Pedersen, L. H. (2013). Dynamic Trading with Liquidity Risk. *The Review of Financial Studies*, 26(5), 1285-1321.
- Moskowitz, T. J., Ooi, Y. H., & Pedersen, L. H. (2012). Time Series Momentum. *Journal of Financial Economics*, 104(3), 410-441.
- Isaac, E., Mathew, J., et al. (2024). Multimodal Approach for Portfolio Optimization Using Deep Reinforcement Learning. *International Conference on Computer Science and Business Analytics*.